

PARTEA A II-A – INTRODUCERE ÎN TEORIA OPTIMIZĂRII

Noțiuni teoretice

1. Concepte fundamentale

$$\begin{array}{ll} \text{minimizați} & f(\mathbf{x}) \\ \text{supusă la} & \mathbf{x} \in \Omega \end{array}$$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$ se numește *funcție obiectiv* (*cost*)

$\mathbf{x} = (x_1, x_2, \dots, x_n)^T \in \Omega \subset \mathbb{R}^n$

x_1, x_2, \dots, x_n se numesc *variabile de decizie*

Ω se numește *mulțimea constrângerilor* sau *mulțimea fezabilă*

Definiția 1. Fie $\Omega \subseteq \mathbb{R}^n$, o mulțime deschisă, și $f : \Omega \rightarrow \mathbb{R}$, o funcție.

- Un punct, $\mathbf{x}^* \in \Omega$, se numește *punct de minim local* pentru f dacă există $\varepsilon > 0$ astfel încât $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, pentru orice $\mathbf{x} \in \Omega \setminus \{\mathbf{x}^*\}$ cu $\|\mathbf{x} - \mathbf{x}^*\| < \varepsilon$.
- Un punct, $\mathbf{x}^* \in \Omega$, se numește *punct de minim global* pentru f dacă $f(\mathbf{x}) \geq f(\mathbf{x}^*)$, pentru orice $\mathbf{x} \in \Omega \setminus \{\mathbf{x}^*\}$.

Dacă \mathbf{x}^* este punct de minim global pentru f , scriem

$$f(\mathbf{x}^*) = \min_{\mathbf{x} \in \Omega} f(\mathbf{x}) \quad \text{și} \quad \mathbf{x}^* = \arg \min_{\mathbf{x} \in \Omega} f(\mathbf{x}).$$

Derivata direcțională a funcției f în direcția lui \mathbf{d} este

$$\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}) = \lim_{\alpha \rightarrow 0} \frac{f(\mathbf{x} + \alpha \mathbf{d}) - f(\mathbf{x})}{\alpha}.$$

Dacă $\|\mathbf{d}\| = 1$, atunci $\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x})$ reprezintă *rata de creștere* a funcției f în punctul \mathbf{x} după direcția lui \mathbf{d} .

Atunci

$$\frac{\partial f}{\partial \mathbf{d}}(\mathbf{x}) = \left. \frac{d}{d\alpha} f(\mathbf{x} + \alpha \mathbf{d}) \right|_{\alpha=0} = \nabla f(\mathbf{x})^T \mathbf{d} = \langle \nabla f(\mathbf{x}), \mathbf{d} \rangle.$$

Definiția 2. Fie $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție de clasă C^1 , și $\mathbf{x} \in \Omega$. O direcție, $\mathbf{d} \in \mathbb{R}^n$, se numește *direcție de descreștere* pentru f dacă

$$\nabla f(\mathbf{x})^T \mathbf{d} < 0.$$

Teorema 3. (Condiție necesară de ordinul I) Fie $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție de clasă C^1 . Dacă \mathbf{x}^* este un punct de minim local pentru f , atunci

$$\nabla f(\mathbf{x}^*) = 0.$$

Teorema 4. (Condiție necesară de ordinul al II-lea) Fie $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție de clasă C^2 , și \mathbf{x}^* , un punct de minim local pentru f . Atunci matricea hessiană a funcției f în punctul \mathbf{x}^* , notată cu $\nabla^2 f(\mathbf{x}^*)$, este pozitiv semidefinită.

Teorema 5. (Condiție suficientă de ordinul al II-lea) Fie $f : \Omega \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție de clasă C^2 , și $\mathbf{x}^* \in \Omega$, un punct staționar al acesteia (i.e., $\nabla f(\mathbf{x}^*) = 0$), astfel încât matricea hessiană $\nabla^2 f(\mathbf{x}^*)$ este pozitiv definită. Atunci \mathbf{x}^* este punct de minim local strict pentru f .

Definiția 6. Fie $\Omega \subseteq \mathbb{R}^n$, o mulțime convexă, și $f : \Omega \rightarrow \mathbb{R}$, o funcție. Spunem că funcția f este *convexă* pe Ω dacă are loc inegalitatea

$$f(\theta \mathbf{x}_1 + (1 - \theta) \mathbf{x}_2) \leq \theta f(\mathbf{x}_1) + (1 - \theta) f(\mathbf{x}_2),$$

pentru orice $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$ și $\theta \in [0, 1]$.

Exemple. a) Fie $\|\cdot\|$, o normă oarecare pe \mathbb{R}^n . Funcția $f(\mathbf{x}) = \|\mathbf{x}\|$ este convexă pe \mathbb{R}^n .

b) Funcția $f(\mathbf{x}) = \max(x_1, x_2, \dots, x_n)$ este convexă pe \mathbb{R}^n .

c) Funcția $f(X) = -\ln(\det X)$ este convexă pe spațiul matricelor pozitiv definite.

Teorema 7. Fie $\Omega \subseteq \mathbb{R}^n$, o mulțime deschisă și convexă, și $f : \Omega \rightarrow \mathbb{R}$, o funcție de clasă C^1 . Atunci f este convexă dacă și numai dacă

$$f(\mathbf{x}_2) \geq f(\mathbf{x}_1) + \nabla f(\mathbf{x}_1)^T (\mathbf{x}_2 - \mathbf{x}_1),$$

pentru orice $\mathbf{x}_1, \mathbf{x}_2 \in \Omega$.

Teorema 8. Fie $\Omega \subseteq \mathbb{R}^n$, o mulțime deschisă și convexă, și $f : \Omega \rightarrow \mathbb{R}$, o funcție de clasă C^2 . Atunci f este convexă dacă și numai dacă matricea hessiană $\nabla^2 f(\mathbf{x})$ este pozitiv semidefinită, pentru orice $\mathbf{x} \in \Omega$.

Exemple. a) Funcția $f(x) = -\log x$ este convexă pe \mathbb{R}_+ .

b) Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică. Funcția $f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{a}^T \mathbf{x} + \mathbf{b}$ este convexă pe \mathbb{R}^n dacă și numai dacă matricea $\nabla^2 f = Q$ este pozitiv semidefinită.

Teorema 9. (Condiții suficiente de ordinul I) Fie $\Omega \subseteq \mathbb{R}^n$, o mulțime deschisă și convexă, și $f : \Omega \rightarrow \mathbb{R}$, o funcție convexă, de clasă C^1 . Dacă $\mathbf{x}^* \in \Omega$ este punct staționar al lui f (i.e., $\nabla f(\mathbf{x}^*) = 0$), atunci \mathbf{x}^* este punct de minim global al lui f .

2. Convergența metodelor de descreștere

2.1. Noțiuni generale

O metodă numerică este dezvoltată în scopul rezolvării diferitelor probleme ce împărtășesc caracteristici similare (de exemplu, continuitate, convexitate etc.).

Datele cunoscute din structura problemei se regăsesc sub numele de *model* (adică formularea problemei, funcțiile ce descriu problema etc.).

Pentru rezolvarea problemei, o metodă numerică va trebui să colecteze informația specifică, iar procesul de colectare a datelor se realizează cu ajutorul unui *oracol* (i.e., unitate de calcul ce returnează date sub forma unor răspunsuri la „întrebări” succesive din partea metodei). În concluzie, metoda numerică rezolvă problema prin colectarea datelor și manipularea „răspunsurilor” oracolului.

Tipuri de oracole:

- oracole de ordinul zero, \mathcal{O}_0 , ce furnizează informație bazată doar pe evaluarea funcției obiectiv, i.e., $f(\mathbf{x})$;

- oracole de ordinul întâi, \mathcal{O}_1 , ce furnizează informație bazată doar pe evaluarea funcției obiectiv și a gradientului acesteia, i.e., $f(\mathbf{x})$ și, respectiv, $\nabla f(\mathbf{x})$;
- oracole de ordinul al doilea, \mathcal{O}_2 , ce furnizează informație bazată doar pe evaluarea funcției obiectiv, a gradientului și a hessianei acesteia, i.e., $f(\mathbf{x})$, $\nabla f(\mathbf{x})$ și, respectiv, $\nabla^2 f(\mathbf{x})$.

Criterii de oprire:

- $\|\nabla f(\mathbf{x})\| < \varepsilon$;
- $|f(\mathbf{x}) - f^*| < \varepsilon$;
- $\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\| < \varepsilon$.

Metodă generică de optimizare numerică:

1. se începe cu un punct inițial dat, $\mathbf{x}^{(0)}$, acuratețea $\varepsilon > 0$ și contorul $k = 0$;
2. la pasul k notăm cu \mathcal{I}_k mulțimea ce conține toată informația acumulată de la oracol până la iterația k :
 - (a) se apelează oracolul \mathcal{O} în punctul $\mathbf{x}^{(k)}$;
 - (b) se actualizează informația $\mathcal{I}_{k+1} = \mathcal{I}_k \cup \mathcal{O}(\mathbf{x}^{(k)})$;
 - (c) se aplică regulile metodei numerice folosind ultimele informații \mathcal{I}_{k+1} pentru calculul următorului punct, $\mathbf{x}^{(k+1)}$;
3. se verifică criteriul de oprire ales; dacă acesta nu este satisfăcut, se repetă pasul 2.

Complexitatea unei metode numerice poate fi exprimată în următoarele forme:

- complexitatea *analitică*, dată de numărul total de apeluri ale oracolului;
- complexitatea *aritmetică*, dată de numărul total de operații aritmetice.

Definiția 10. Fie $\{\mathbf{x}^{(k)}\}_{k \geq 0}$, un șir convergent la \mathbf{x}^* , i.e., $\lim_{k \rightarrow \infty} \|\mathbf{x}^{(k)} - \mathbf{x}^*\| = 0$. Spunem că *ordinul de convergență* a șirului $\{\mathbf{x}^{(k)}\}_{k \geq 0}$ este $p \in \mathbb{R}$ dacă

$$0 < \limsup_{k \rightarrow \infty} \frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^p} < \infty.$$

- **Convergență liniară:** există $\beta \in (0, 1)$ astfel încât

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \beta \|\mathbf{x}^{(k)} - \mathbf{x}^*\|, \quad \text{pentru orice } k \geq 0.$$

- **Convergență superliniară:** există un șir, $(\beta_k)_{k \geq 0}$, cu $\beta_k \rightarrow 0$, astfel încât

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \beta_k \|\mathbf{x}^{(k)} - \mathbf{x}^*\|, \quad \text{pentru orice } k \geq 0.$$

- **Convergență subliniară:**

$$\lim_{k \rightarrow \infty} \frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|} = 1.$$

- **Convergență pătratică:** există $\beta \in (0, \infty)$ astfel încât

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \beta \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2, \quad \text{pentru orice } k \geq 0.$$

Exemple. a) Șirul $(\frac{1}{k})_{k \geq 1}$ are o convergență subliniară.

b) Șirul $(\frac{1}{k^\alpha})_{k \geq 1}$, cu $\alpha > 0$, fixat, are o convergență subliniară.

c) Șirul $(\frac{1}{2^k})_{k \geq 0}$ are o convergență liniară.

d) Șirul $(10^{-2^k})_{k \geq 0}$ are o convergență pătratică.

e) Șirul $(\frac{1}{k^k})_{k \geq 1}$ are o convergență superliniară.

2.2. Metode de descreștere

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)},$$

unde:

- $\mathbf{d}^{(k)}$ este o *direcție de descreștere* pentru f în $\mathbf{x}^{(k)}$;
- $\alpha_k \in (0, 1]$ este *lungimea pasului*.

Scopuri:

- $f(\mathbf{x}^{(k+1)}) < f(\mathbf{x}^{(k)})$;
- $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$.

2.3. Metode de alegere a lungimii pasului

Metoda ideală

$$\alpha_k = \arg \min_{0 < \alpha \leq 1} f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)})$$

Condițiile Wolfe

(W1): $f(\mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}) \leq f(\mathbf{x}^{(k)}) + c_1 \alpha_k \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}$, cu $c_1 \in (0, 1)$;

(W2): $\nabla f(\mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)})^T \mathbf{d}^{(k)} \geq c_2 \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)}$, cu $0 < c_1 < c_2 < 1$.

Algoritmul backtracking:

1. se aleg $\alpha > 0$ (i.e., $\alpha = 1$), $\rho, c_1 \in (0, 1)$;
2. cât timp

$$f(\mathbf{x}^{(k)} + \alpha \mathbf{d}^{(k)}) > f(\mathbf{x}^{(k)}) + c_1 \alpha \nabla f(\mathbf{x}^{(k)})^T \mathbf{d}^{(k)},$$

se actualizează $\alpha \leftarrow \rho \alpha$;

3. ieșirea: $\alpha_k = \alpha$.

2.4. Convergența metodelor de descreștere

Definiția 11. Fie $f : \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție diferențiabilă. Spunem că f are *gradient L -Lipschitz continuu* dacă există $L > 0$ astfel încât

$$\|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \|\mathbf{x} - \mathbf{y}\|,$$

pentru orice $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$.

Teorema 12. (Teorema de convergență a metodelor de descreștere)

Considerăm problema de optimizare fără constrângeri

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}),$$

unde $f \in C^1$ este mărginită inferior și are gradient L -Lipschitz continuu. Fie metoda iterativă $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$, unde, pentru orice $k \geq 0$, $\mathbf{d}^{(k)}$

este o direcție de descreștere și pasul α_k este ales astfel încât condițiile Wolfe sunt satisfăcute. Atunci

$$\sum_{k=0}^{\infty} \cos^2 \theta_k \left\| \nabla f \left(\mathbf{x}^{(k)} \right) \right\|^2 < \infty,$$

unde θ_k este unghiul făcut de direcția $\mathbf{d}^{(k)}$ cu gradientul $\nabla f \left(\mathbf{x}^{(k)} \right)$.

3. Metoda gradientului (a celei mai abrupte descreșteri)

Fie $\mathbf{x}^{(0)}$, un punct de pornire.

Considerăm punctul $\mathbf{x} = \mathbf{x}^{(0)} - \alpha \nabla f \left(\mathbf{x}^{(0)} \right)$.

Putem scrie

$$f(\mathbf{x}) = f \left(\mathbf{x}^{(0)} - \alpha \nabla f \left(\mathbf{x}^{(0)} \right) \right) = f \left(\mathbf{x}^{(0)} \right) - \alpha \left\| \nabla f \left(\mathbf{x}^{(0)} \right) \right\|^2 + o(\alpha).$$

Dacă $\nabla f \left(\mathbf{x}^{(0)} \right) \neq \mathbf{0}$, atunci, pentru $\alpha > 0$, suficient de mic, avem

$$f(\mathbf{x}) < f \left(\mathbf{x}^{(0)} \right).$$

Algoritmul celei mai abrupte descreșteri (The Method of Steepest Descent)

Fie $\mathbf{x}^{(0)}$, un punct de pornire.

Atunci

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \nabla f \left(\mathbf{x}^{(k)} \right), \quad k = 0, 1, \dots,$$

unde

$$\alpha_k = \arg \min_{\alpha \geq 0} f \left(\mathbf{x}^{(k)} - \alpha \nabla f \left(\mathbf{x}^{(k)} \right) \right).$$

Teorema 13. Vectorul $\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$ este ortogonal pe vectorul $\mathbf{x}^{(k+2)} - \mathbf{x}^{(k+1)}$, pentru orice $k \geq 0$.

Teorema 14. Dacă $\nabla f \left(\mathbf{x}^{(k)} \right) \neq \mathbf{0}$, atunci $f \left(\mathbf{x}^{(k+1)} \right) < f \left(\mathbf{x}^{(k)} \right)$.

Problema 1. Să se minimizeze funcția

$$f(x_1, x_2) = 2x_1^2 - 2x_1x_2 + x_2^2,$$

unde $\mathbf{x}^{(0)} = (2, 3)^T$.

Soluție.

$$\nabla f(x_1, x_2) = (4x_1 - 2x_2, 2x_2 - 2x_1)^T$$

$$\nabla f \left(\mathbf{x}^{(0)} \right) = (2, 2)^T$$

$$\alpha_0 = \arg \min_{\alpha \geq 0} f \left((2, 3)^T - \alpha (2, 2)^T \right)$$

$$= \arg \min_{\alpha \geq 0} f \left((2 - 2\alpha, 3 - 2\alpha)^T \right)$$

$$= \arg \min_{\alpha \geq 0} \left(2(2 - 2\alpha)^2 - 2(2 - 2\alpha)(3 - 2\alpha) + (3 - 2\alpha)^2 \right)$$

$$= \arg \min_{\alpha \geq 0} (4\alpha^2 - 16\alpha + 5) = 2$$

$$\mathbf{x}^{(1)} = \mathbf{x}^{(0)} - 2\nabla f \left(\mathbf{x}^{(0)} \right) = (-2, -1)^T \text{ etc.}$$

Problema 2. Să se minimizeze funcția

$$f(x_1, x_2, x_3) = (x_1 - 4)^4 + (x_2 - 4)^2 + 4(x_3 + 5)^4,$$

unde $\mathbf{x}^{(0)} = (4, 2, -1)^T$.

Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică pozitiv definită, și $\mathbf{b} \in \mathbb{R}^n$.

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

Notăm $\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)})$.

Avem

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \mathbf{g}^{(k)},$$

unde

$$\begin{aligned} \alpha_k &= \arg \min_{\alpha \geq 0} f(\mathbf{x}^{(k)} - \alpha \mathbf{g}^{(k)}) \\ &= \arg \min_{\alpha \geq 0} \left(\frac{1}{2} (\mathbf{x}^{(k)} - \alpha \mathbf{g}^{(k)})^T Q (\mathbf{x}^{(k)} - \alpha \mathbf{g}^{(k)}) - \mathbf{b}^T (\mathbf{x}^{(k)} - \alpha \mathbf{g}^{(k)}) \right). \end{aligned}$$

Se obține

$$\alpha_k = \frac{(\mathbf{g}^{(k)})^T \mathbf{g}^{(k)}}{(\mathbf{g}^{(k)})^T Q \mathbf{g}^{(k)}}.$$

Algoritmul celei mai abrupte descreșteri (The Method of Steepest Descent)

Fie $\mathbf{x}^{(0)}$, un punct de pornire.

Atunci

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \frac{(\mathbf{g}^{(k)})^T \mathbf{g}^{(k)}}{(\mathbf{g}^{(k)})^T Q \mathbf{g}^{(k)}} \mathbf{g}^{(k)}, \quad k = 0, 1, \dots,$$

unde

$$\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)}) = Q \mathbf{x}^{(k)} - \mathbf{b}.$$

Teorema 15. Avem $\mathbf{x}^{(k)} \rightarrow \mathbf{x}^*$, pentru orice $\mathbf{x}^{(0)}$.

Teorema 16. Are loc inegalitatea

$$f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^*) \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^2 \left(f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \right),$$

unde $\kappa = \frac{\lambda_{\max}}{\lambda_{\min}}$ este numărul de condiționare al matricei Q în raport cu norma spectrală.

Teorema 17. Fie $f \in C^2$. Presupunem că iterațiile metodei gradient, generate cu procedura de căutare ideală a pasului, converge la un punct, \mathbf{x}^* , pentru care matricea $\nabla^2 f(\mathbf{x}^*)$ este pozitiv definită. Fie un scalar, $\beta \in \left(\left(\frac{\kappa - 1}{\kappa + 1} \right)^2, 1 \right)$, unde κ este numărul de condiționare al matricei $\nabla^2 f(\mathbf{x}^*)$ în raport cu norma spectrală. Atunci, pentru k suficient de mare, avem

$$f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^*) \leq \beta \left(f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \right).$$

4. Metode de direcții conjugate

4.1. Noțiuni generale

Definiția 18. Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică. Spunem că direcțiile $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(m)}$ sunt *Q-conjugate* (sau *Q-ortogonale*) dacă

$$(\mathbf{d}^{(i)})^T Q \mathbf{d}^{(j)} = 0, \quad \text{pentru orice } i \neq j.$$

Propoziția 19. Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică pozitiv definită. Dacă direcțiile $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(k)} \in \mathbb{R}^n$, cu $k \leq n-1$, sunt nenule și Q -conjugate, atunci acestea sunt liniar independente.

Algoritmul Gram-Schmidt (variantă)

Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică pozitiv definită, și $\{\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots, \mathbf{p}^{(n-1)}\}$, o familie de vectori liniar independenți din \mathbb{R}^n .

Construim vectorii

$$\begin{aligned} \mathbf{d}^{(0)} &= \mathbf{p}^{(0)}, \\ \mathbf{d}^{(k+1)} &= \mathbf{p}^{(k+1)} - \sum_{i=0}^k \frac{(\mathbf{p}^{(k+1)})^T Q \mathbf{d}^{(i)}}{(\mathbf{d}^{(i)})^T Q \mathbf{d}^{(i)}} \mathbf{d}^{(i)}. \end{aligned}$$

Atunci vectorii $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$ sunt Q -conjugăți.

Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică pozitiv definită, și $\mathbf{b} \in \mathbb{R}^n$.

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

4.2. Algoritmul direcțiilor conjugate

Fie $\mathbf{x}^{(0)}$, un punct de pornire, și $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$, n direcții Q -conjugate. Pentru $k = 0, 1, \dots$, considerăm

$$\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)}) = Q \mathbf{x}^{(k)} - \mathbf{b}$$

și

$$\alpha_k = -\frac{(\mathbf{g}^{(k)})^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T Q \mathbf{d}^{(k)}}.$$

Atunci

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}.$$

Teorema 20. Pentru orice punct de pornire, $\mathbf{x}^{(0)}$, algoritmul anterior converge la un unic punct, \mathbf{x}^* , soluție a sistemului $Q \mathbf{x} = \mathbf{b}$, în n pași (i.e., $\mathbf{x}^* = \mathbf{x}^{(n)}$).

Problema 4. Să se minimizeze

$$f(x_1, x_2) = \frac{1}{2} \mathbf{x}^T \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} \mathbf{x} - \mathbf{x}^T \begin{pmatrix} -1 \\ 1 \end{pmatrix},$$

folosind metoda direcției conjugate, cu $\mathbf{x}^{(0)} = (0, 0)^T$, $\mathbf{d}^{(0)} = (1, 0)^T$ și $\mathbf{d}^{(1)} = (-\frac{3}{8}, \frac{3}{4})^T$.

Soluție.

$$\begin{aligned} \mathbf{g}^{(0)} &= \nabla f(\mathbf{x}^{(0)}) = -\mathbf{b} = (1, -1)^T \\ \alpha_0 &= -\frac{(\mathbf{g}^{(0)})^T \mathbf{d}^{(0)}}{(\mathbf{d}^{(0)})^T Q \mathbf{d}^{(0)}} = -\frac{(1, -1) \begin{pmatrix} 1 \\ 0 \end{pmatrix}}{(1, 0) \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} 1 \\ 0 \end{pmatrix}} = -\frac{1}{4} \\ \mathbf{x}^{(1)} &= \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)} = \begin{pmatrix} 0 \\ 0 \end{pmatrix} - \frac{1}{4} \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} -\frac{1}{4} \\ 0 \end{pmatrix} \end{aligned}$$

$$\begin{aligned}\mathbf{g}^{(1)} &= \nabla f(\mathbf{x}^{(1)}) = Q\mathbf{x}^{(1)} - \mathbf{b} = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} -\frac{1}{4} \\ 0 \end{pmatrix} - \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ -\frac{3}{2} \end{pmatrix} \\ \alpha_1 &= -\frac{(\mathbf{g}^{(1)})^T \mathbf{d}^{(1)}}{(\mathbf{d}^{(1)})^T Q \mathbf{d}^{(1)}} = -\frac{(0, -\frac{3}{2}) \begin{pmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{pmatrix}}{(-\frac{3}{8}, \frac{3}{4}) \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} \begin{pmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{pmatrix}} = 2 \\ \mathbf{x}^{(2)} &= \mathbf{x}^{(1)} + \alpha_1 \mathbf{d}^{(1)} = \begin{pmatrix} -\frac{1}{4} \\ 0 \end{pmatrix} + 2 \begin{pmatrix} -\frac{3}{8} \\ \frac{3}{4} \end{pmatrix} = \begin{pmatrix} -1 \\ \frac{3}{2} \end{pmatrix} = \mathbf{x}^*\end{aligned}$$

4.3. Metoda gradientilor conjugați

Fie $Q \in \mathcal{M}_n(\mathbb{R})$, o matrice simetrică pozitiv definită, și $\mathbf{b} \in \mathbb{R}^n$.

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

Algoritmul gradientilor conjugați

Fie $\mathbf{x}^{(0)}$, un punct de pornire.

Alegem

$$\mathbf{d}^{(0)} = -\nabla f(\mathbf{x}^{(0)}) = -\mathbf{g}^{(0)}.$$

Atunci $\mathbf{x}^{(1)} = \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)}$, unde

$$\alpha_0 = -\frac{(\mathbf{g}^{(0)})^T \mathbf{d}^{(0)}}{(\mathbf{d}^{(0)})^T Q \mathbf{d}^{(0)}}.$$

La pasul k :

$$\mathbf{g}^{(k)} = \nabla f(\mathbf{x}^{(k)}),$$

$$\mathbf{d}^{(k)} = -\mathbf{g}^{(k)} + \beta_{k-1} \mathbf{d}^{(k-1)},$$

unde

$$\beta_{k-1} = \frac{(\mathbf{g}^{(k)})^T Q \mathbf{d}^{(k-1)}}{(\mathbf{d}^{(k-1)})^T Q \mathbf{d}^{(k-1)}}.$$

Considerăm

$$\alpha_k = -\frac{(\mathbf{g}^{(k)})^T \mathbf{d}^{(k)}}{(\mathbf{d}^{(k)})^T Q \mathbf{d}^{(k)}}.$$

Atunci $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}^{(k)}$.

Propoziția 21. În algoritmul gradientilor conjugați, direcțiile $\mathbf{d}^{(0)}, \mathbf{d}^{(1)}, \dots, \mathbf{d}^{(n-1)}$ sunt Q -conjugate.

Problema 5. Să se minimizeze

$$f(x_1, x_2, x_3) = \frac{3}{2}x_1^2 + 2x_2^2 + \frac{3}{2}x_3^2 + x_1x_3 + 2x_2x_3 - 3x_1 - x_3,$$

folosind metoda gradientului conjugat, cu $\mathbf{x}^{(0)} = (0, 0, 0)^T$.

Soluție.

$$f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} - \mathbf{b}^T \mathbf{x}, \text{ cu } Q = \begin{pmatrix} 3 & 0 & 1 \\ 0 & 4 & 2 \\ 1 & 2 & 3 \end{pmatrix} \text{ și } \mathbf{b} = \begin{pmatrix} 3 \\ 0 \\ 1 \end{pmatrix}$$

$$\mathbf{g}(\mathbf{x}) = \nabla f(\mathbf{x}) = Q\mathbf{x} - \mathbf{b} =$$

$$\begin{aligned}
&= (3x_1 + x_3 - 3, 4x_2 + 2x_3, x_1 + 2x_2 + 3x_3 - 1)^T \\
\mathbf{g}^{(0)} &= (-3, 0, -1)^T \\
\mathbf{d}^{(0)} &= -\mathbf{g}^{(0)} \\
\alpha_0 &= -\frac{(\mathbf{g}^{(0)})^T \mathbf{d}^{(0)}}{(\mathbf{d}^{(0)})^T Q \mathbf{d}^{(0)}} = \frac{10}{36} = 0,2778 \\
\mathbf{x}^{(1)} &= \mathbf{x}^{(0)} + \alpha_0 \mathbf{d}^{(0)} = (0,8333; 0; 0,2778)^T \\
\mathbf{g}^{(1)} &= \nabla f(\mathbf{x}^{(1)}) = (-0,2222; 0,5556; 0,6667)^T \\
\beta_0 &= \frac{(\mathbf{g}^{(1)})^T Q \mathbf{d}^{(0)}}{(\mathbf{d}^{(0)})^T Q \mathbf{d}^{(0)}} = 0,08025 \\
\mathbf{d}^{(1)} &= -\mathbf{g}^{(1)} + \beta_0 \mathbf{d}^{(0)} = (0,4630; -0,5556; -0,5864)^T \\
\alpha_1 &= -\frac{(\mathbf{g}^{(1)})^T \mathbf{d}^{(1)}}{(\mathbf{d}^{(1)})^T Q \mathbf{d}^{(1)}} = 0,2187 \\
\mathbf{x}^{(2)} &= \mathbf{x}^{(1)} + \alpha_1 \mathbf{d}^{(1)} = (0,9346; -0,1215; 0,1495)^T \\
\mathbf{g}^{(2)} &= \nabla f(\mathbf{x}^{(2)}) = (-0,04673; -0,1869; 0,1402)^T \\
\beta_1 &= \frac{(\mathbf{g}^{(2)})^T Q \mathbf{d}^{(1)}}{(\mathbf{d}^{(1)})^T Q \mathbf{d}^{(1)}} = 0,07075 \\
\mathbf{d}^{(2)} &= -\mathbf{g}^{(2)} + \beta_1 \mathbf{d}^{(1)} = (0,07948; 0,1476; -0,1817)^T \\
\alpha_2 &= -\frac{(\mathbf{g}^{(2)})^T \mathbf{d}^{(2)}}{(\mathbf{d}^{(2)})^T Q \mathbf{d}^{(2)}} = 0,8231 \\
\mathbf{x}^{(3)} &= \mathbf{x}^{(2)} + \alpha_2 \mathbf{d}^{(2)} = (1,000; 0,000; 0,000)^T = \mathbf{x}^*
\end{aligned}$$

5. Stochastic gradient descent

Se consideră un set de date, $\{(\mathbf{a}_i, y_i)\}_{i=1, \dots, n}$, cu $\mathbf{a}_i \in \mathbb{R}^d$ și $y_i \in \mathbb{R}$, ce urmează o distribuție necunoscută.

Problema de optimizare:

$$\min_{\mathbf{x} \in \mathbb{R}^d} f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \ell(h(\mathbf{x}, \mathbf{a}_i), y_i)$$

Exemple de funcții de pierdere („loss functions”):

- „square loss”: $\ell(h(\mathbf{x}, \mathbf{a}_i), y_i) = (y_i - h(\mathbf{x}, \mathbf{a}_i))^2$;
- „cross-entropy loss”: $\ell(h(\mathbf{x}, \mathbf{a}_i), y_i) = -y_i \ln h(\mathbf{x}, \mathbf{a}_i) - (1 - y_i) \ln(1 - h(\mathbf{x}, \mathbf{a}_i))$.

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \nabla f(\mathbf{x}^{(k)})$$

$$\nabla f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x})$$

$$\nabla f(\mathbf{x}) \approx \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \nabla f_i(\mathbf{x}),$$

unde \mathcal{I} este o submulțime aleatoare a lui $\{1, 2, \dots, n\}$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \cdot \frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \nabla f_i(\mathbf{x})$$

Propoziția 22. Presupunem că elementele lui \mathcal{I} sunt variabile aleatoare i.i.d. ce urmează o distribuție uniformă pe $\{1, 2, \dots, n\}$. Atunci gradientul stocastic este un estimator nedeplasat al gradientului complet, i.e.,

$$E \left(\frac{1}{|\mathcal{I}|} \sum_{i \in \mathcal{I}} \nabla f_i(\mathbf{x}) \right) = \nabla f(\mathbf{x}).$$

„32 could be a good default value for the mini-batch size”

Referință: Yoshua Bengio, Practical recommendations for gradient-based training of deep architectures, în Grégoire Montavon, Geneviève B. Orr, Klaus-Robert Müller (eds.), *Neural networks: Tricks of the trade*, pp. 437–478, Springer, 2012.

6. Gradient descent with momentum

$$\mathbf{m}^{(k+1)} = \gamma_k \mathbf{m}^{(k)} + (1 - \gamma_k) \nabla f(\mathbf{x}^{(k)})$$

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \mathbf{m}^{(k+1)}$$

sau, echivalent,

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \tilde{\alpha}_k \nabla f(\mathbf{x}^{(k)}) + \tilde{\beta}_k (\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)}),$$

unde

$$\tilde{\alpha}_k = \alpha_k (1 - \gamma_k) \quad \text{și} \quad \tilde{\beta}_k = \frac{\alpha_k \gamma_k}{\alpha_{k-1}}.$$

7. Nesterov's Accelerated Gradient

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \alpha_k \nabla f\left(\mathbf{x}^{(k)} + \beta_k (\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)})\right) + \beta_k (\mathbf{x}^{(k)} - \mathbf{x}^{(k-1)})$$

Propoziția 23. Fie $f : \mathbb{R}^n \rightarrow \mathbb{R}$, o funcție convexă, de clasă C^1 , cu gradientul L -Lipschitz continuu. Fie $\mathbf{x}^{(0)} \in \mathbb{R}^n$, $\mathbf{x}^{(-1)} = \mathbf{x}^{(0)}$, $\alpha_k = \frac{1}{L}$, $\lambda_{-1} = 0$, $\lambda_k = \frac{1 + \sqrt{1 + 4\lambda_{k-1}^2}}{2}$ și $\beta_k = \frac{\lambda_{k-1} - 1}{\lambda_k}$, pentru orice $k \geq 0$. Atunci, pentru orice $k \geq 0$, are loc inegalitatea


$$f(\mathbf{x}^{(k)}) - f(\mathbf{x}^*) \leq \frac{2L}{(k+1)^2} \|\mathbf{x}^{(0)} - \mathbf{x}^*\|^2.$$

8. Rețele neuronale artificiale – Algoritmul Backpropagation

Problemă de optimizare

Pornind de la un set de date, $\{(\mathbf{x}_{d,i}, \mathbf{y}_{d,i})\}_{i=1,p} \subset \mathbb{R}^n \times \mathbb{R}^m$, se caută o funcție, $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$, care să minimizeze un criteriu de eroare, de exemplu, suma pătratelor erorilor:

$$\sum_{i=1}^p (\mathbf{y}_{d,i} - F(\mathbf{x}_{d,i}))^2.$$



$$v_j = \sum_{i=1}^n w_{ji}^h x_i$$

$$z_j = f_j^h(v_j) = f_j^h\left(\sum_{i=1}^n w_{ji}^h x_i\right)$$

$$\begin{aligned} y_s &= f_s^o\left(\sum_{j=1}^l w_{sj}^o z_j\right) \\ &= f_s^o\left(\sum_{j=1}^l w_{sj}^o f_j^h\left(\sum_{i=1}^n w_{ji}^h x_i\right)\right), \quad s = \overline{1, m} \end{aligned}$$

$$(\mathbf{x}_d, \mathbf{y}_d) \in \mathbb{R}^n \times \mathbb{R}^m$$

$$\min_{w_{ji}^h, w_{sj}^o} \frac{1}{2} \sum_{s=1}^m (y_{ds} - y_s)^2$$

$$\mathbf{w} = \left\{ w_{ji}^h, w_{sj}^o : i = \overline{1, n}, j = \overline{1, l}, s = \overline{1, m} \right\}$$

$$\begin{aligned} E(\mathbf{w}) &= \frac{1}{2} \sum_{s=1}^m (y_{ds} - y_s)^2 \\ &= \frac{1}{2} \sum_{s=1}^m \left(y_{ds} - f_s^o\left(\sum_{j=1}^l w_{sj}^o f_j^h\left(\sum_{i=1}^n w_{ji}^h x_{di}\right)\right) \right)^2 \end{aligned}$$

Calculăm $\frac{\partial E}{\partial w_{sj}^o}$:

$$\begin{aligned} E(\mathbf{w}) &= \frac{1}{2} \sum_{s=1}^m \left(y_{ds} - f_s^o\left(\sum_{j=1}^l w_{sj}^o z_j\right) \right)^2 \\ z_j &= f_j^h\left(\sum_{i=1}^n w_{ji}^h x_{di}\right), \quad j = \overline{1, l} \end{aligned}$$

$$\frac{\partial E}{\partial w_{sj}^o}(\mathbf{w}) = -(y_{ds} - y_s) f_s^{o'}\left(\sum_{q=1}^l w_{sq}^o z_q\right) z_j$$

$$\frac{\partial E}{\partial w_{sj}^o}(\mathbf{w}) = -\delta_s z_j$$

Calculăm $\frac{\partial E}{\partial w_{ji}^h}$:

$$E(\mathbf{w}) = \frac{1}{2} \sum_{s=1}^m \left(y_{ds} - f_s^o\left(\sum_{j=1}^l w_{sj}^o f_j^h\left(\sum_{i=1}^n w_{ji}^h x_{di}\right)\right) \right)^2$$

$$\frac{\partial E}{\partial w_{ji}^h}(\mathbf{w}) = -\sum_{s=1}^m (y_{ds} - y_s) f_s^{o'}\left(\sum_{q=1}^l w_{sq}^o z_q\right) w_{sj}^o f_j^{h'}\left(\sum_{r=1}^n w_{jr}^h x_{dr}\right) x_{di}$$

$$\frac{\partial E}{\partial w_{ji}^h}(\mathbf{w}) = - \left(\sum_{s=1}^m \delta_s w_{sj}^o \right) f_j^{h'}(v_j) x_{di}$$

Algoritmul Backpropagation

$$\begin{aligned} w_{sj}^{o(k+1)} &= w_{sj}^{o(k)} + \eta \delta_s^{(k)} z_j^{(k)} \\ w_{ji}^{h(k+1)} &= w_{ji}^{h(k)} + \eta \left(\sum_{s=1}^m \delta_s^{(k)} w_{sj}^{o(k)} \right) f_j^{h'}(v_j^{(k)}) x_{di} \\ v_j^{(k)} &= \sum_{i=1}^n w_{ji}^{h(k)} x_{di} \\ z_j^{(k)} &= f_j^h(v_j^{(k)}) \\ y_s^{(k)} &= f_s^o \left(\sum_{q=1}^l w_{sq}^{o(k)} z_q^{(k)} \right) \\ \delta_s^{(k)} &= \left(y_{ds} - y_s^{(k)} \right) f_s^{o'} \left(\sum_{q=1}^l w_{sq}^{o(k)} z_q^{(k)} \right) \end{aligned}$$

9. Metoda lui Newton

$$f(\mathbf{x}) \approx \underbrace{f(\mathbf{x}^{(k)}) + \left(\mathbf{g}^{(k)} \right)^T (\mathbf{x} - \mathbf{x}^{(k)}) + \frac{1}{2} (\mathbf{x} - \mathbf{x}^{(k)})^T \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})}_{q(\mathbf{x})}$$

$$\mathbf{0} = \nabla q(\mathbf{x}) = \mathbf{g}^{(k)} + \nabla^2 f(\mathbf{x}^{(k)}) (\mathbf{x} - \mathbf{x}^{(k)})$$

Presupunem că $\nabla^2 f(\mathbf{x}^{(k)}) \succ 0$.

Atunci

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - \left(\nabla^2 f(\mathbf{x}^{(k)}) \right)^{-1} \mathbf{g}^{(k)}.$$

Teorema 24. (Convergența locală pătratică a metodei Newton) Fie $f \in C^2$ și \mathbf{x}^* , un punct de minim local, ce satisface condițiile suficiente de ordinul al doilea (i.e., $\nabla f(\mathbf{x}^*) = 0$ și $\nabla^2 f(\mathbf{x}^*) \succ 0$). Fie $l > 0$ astfel încât $\nabla^2 f(\mathbf{x}^*) \succeq lI_n$. Presupunem că $\nabla^2 f(\mathbf{x})$ este Lipschitz, i.e., există $M > 0$ astfel încât $\|\nabla^2 f(\mathbf{x}) - \nabla^2 f(\mathbf{y})\| \leq M \|\mathbf{x} - \mathbf{y}\|$, pentru orice $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$. Dacă $\mathbf{x}^{(0)}$ este suficient de aproape de \mathbf{x}^* , i.e., $\|\mathbf{x}^{(0)} - \mathbf{x}^*\| \leq \frac{2}{3} \cdot \frac{l}{M}$, atunci iterația Newton $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - (\nabla^2 f(\mathbf{x}^{(k)}))^{-1} \nabla f(\mathbf{x}^{(k)})$ are proprietatea că șirul generat $(\mathbf{x}^{(k)})_{k \geq 0}$ converge la \mathbf{x}^* cu rata pătratică, mai precis, $\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq \frac{3M}{2l} \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2$, pentru orice $k \geq 0$.

Problema 7. Să se minimizeze funcția lui Powell

$$f(x_1, x_2, x_3, x_4) = (x_1 + 10x_2)^2 + 5(x_3 - x_4)^2 + (x_2 - 2x_3)^4 + 10(x_1 - x_4)^4,$$

unde $\mathbf{x}^{(0)} = (3, -1, 0, 1)^T$.

Soluție.

$$\begin{aligned}
f(\mathbf{x}^{(0)}) &= 215 \\
\nabla f(\mathbf{x}) &= \begin{pmatrix} 2(x_1 + 10x_2) + 40(x_1 - x_4)^3 \\ 20(x_1 + 10x_2) + 4(x_2 - 2x_3)^3 \\ 10(x_3 - x_4) - 8(x_2 - 2x_3)^3 \\ -10(x_3 - x_4) - 40(x_1 - x_4)^3 \end{pmatrix} \\
\nabla^2 f(\mathbf{x}) &= \begin{pmatrix} 2 + 120(x_1 - x_4)^2 & 20 & 0 & -120(x_1 - x_4)^2 \\ 20 & 200 + 12(x_2 - 2x_3)^2 & -24(x_2 - 2x_3)^2 & 0 \\ 0 & -24(x_2 - 2x_3)^2 & 10 + 48(x_2 - 2x_3)^2 & -10 \\ -120(x_1 - x_4)^2 & 0 & -10 & 10 + 120(x_1 - x_4)^2 \end{pmatrix} \\
\mathbf{g}^{(0)} &= (306, -144, -2, -310)^T \\
\nabla^2 f(\mathbf{x}^{(0)}) &= \begin{pmatrix} 482 & 20 & 0 & -480 \\ 20 & 212 & -24 & 0 \\ 0 & -24 & 58 & -10 \\ -480 & 0 & -10 & 490 \end{pmatrix} \\
(\nabla^2 f(\mathbf{x}^{(0)}))^{-1} &= \begin{pmatrix} 0,1126 & -0,0089 & 0,0154 & 0,1106 \\ -0,0089 & 0,0057 & 0,0008 & -0,0087 \\ 0,0154 & 0,0008 & 0,0203 & 0,0155 \\ 0,1106 & -0,0087 & 0,0155 & 0,1107 \end{pmatrix} \\
(\nabla^2 f(\mathbf{x}^{(0)}))^{-1} \mathbf{g}^{(0)} &= (1,4127; -0,8413; -0,2540; 0,7460)^T \\
\mathbf{x}^{(1)} &= \mathbf{x}^{(0)} - (\nabla^2 f(\mathbf{x}^{(0)}))^{-1} \mathbf{g}^{(0)} = (1,5873; -0,1587; 0,2540; 0,2540)^T \\
f(\mathbf{x}^{(1)}) &= 31,8 \\
\mathbf{g}^{(1)} &= (94,81; -1,179; 2,371; -94,81)^T \\
\nabla^2 f(\mathbf{x}^{(1)}) &= \begin{pmatrix} 215,3 & 20 & 0 & -213,3 \\ 20 & 205,3 & -10,67 & 0 \\ 0 & -10,67 & 31,34 & -10 \\ -213,3 & 0 & -10 & 223,3 \end{pmatrix} \\
(\nabla^2 f(\mathbf{x}^{(1)}))^{-1} \mathbf{g}^{(1)} &= (0,5291; -0,0529; 0,0846; 0,0846)^T \\
\mathbf{x}^{(2)} &= \mathbf{x}^{(1)} - (\nabla^2 f(\mathbf{x}^{(1)}))^{-1} \mathbf{g}^{(1)} = (1,0582; -0,1058; 0,1694; 0,1694)^T \\
f(\mathbf{x}^{(2)}) &= 6,28 \\
\mathbf{g}^{(2)} &= (28,09; -0,3475; 0,7031; -28,08)^T \\
\nabla^2 f(\mathbf{x}^{(2)}) &= \begin{pmatrix} 96,80 & 20 & 0 & -94,80 \\ 20 & 202,4 & -4,744 & 0 \\ 0 & -4,744 & 19,49 & -10 \\ -94,80 & 0 & -10 & 104,80 \end{pmatrix} \\
\mathbf{x}^{(3)} &= \mathbf{x}^{(2)} - (\nabla^2 f(\mathbf{x}^{(2)}))^{-1} \mathbf{g}^{(2)} = (0,7037; -0,0704; 0,1121; 0,1111)^T \\
f(\mathbf{x}^{(3)}) &= 1,24
\end{aligned}$$

10. Introducere în programare liniară

10.1. Noțiuni generale

Scop. Determinarea valorilor variabilelor de decizie care minimizează/maximizează o funcție obiectiv liniară, atunci când variabilele de decizie sunt supuse unor constrângeri liniare.

Forma standard a unei probleme de programare liniară

$$\begin{aligned}
&\text{minimizăți} && \mathbf{c}^T \mathbf{x} \\
&\text{supusă la} && A\mathbf{x} = \mathbf{b} \\
&&& \mathbf{x} \geq 0
\end{aligned}$$

unde $\mathbf{c} \in \mathbb{R}^n$, $A \in \mathcal{M}_{m,n}(\mathbb{R})$ și $\mathbf{b} \in \mathbb{R}^m$, cu $m < n$ și $\text{rang } A = m$.

Scriem $A = (B \mid D)$, cu $B \in \mathcal{M}_m(\mathbb{R})$, inversabilă, și $D \in \mathcal{M}_{m,n-m}(\mathbb{R})$.

Soluția ecuației $B\mathbf{x}_B = \mathbf{b}$ este $\mathbf{x}_B = B^{-1}\mathbf{b}$.

Definițiile 25.

- Vectorul $\mathbf{x} = (\mathbf{x}_B^T, \mathbf{0}^T)^T$ se numește *soluție de bază* a sistemului $A\mathbf{x} = \mathbf{b}$ în raport cu baza B .
- Componentele vectorului \mathbf{x}_B se numesc *variabile de bază* și coloanele matricei B se numesc *coloane de bază*.
- Dacă anumite variabile de bază ale unei soluții de bază sunt nule, atunci soluția de bază respectivă se numește *soluție de bază degenerată*.
- Un vector, \mathbf{x} , ce satisface $A\mathbf{x} = \mathbf{b}$ și $\mathbf{x} \geq 0$ se numește *soluție fezabilă*.
- O soluție fezabilă ce este și soluție de bază se numește *soluție fezabilă de bază*.
- O soluție fezabilă de bază ce este și soluție de bază degenerată se numește *soluție fezabilă de bază degenerată*.

Definițiile 26.

- Orice vector, \mathbf{x} , pentru care se atinge valoarea minimă a funcției obiectiv, $\mathbf{c}^T\mathbf{x}$, pe mulțimea vectorilor ce satisfac constrângerile $A\mathbf{x} = \mathbf{b}$ și $\mathbf{x} \geq 0$, se numește *soluție fezabilă optimă*.
- O soluție fezabilă optimă ce este și soluție de bază se numește *soluție fezabilă de bază optimă*.

Teorema 27. (Teorema fundamentală a programării liniare)

- Orice problemă de programare liniară se încadrează în exact una dintre următoarele trei situații:
 1. nu este fezabilă;
 2. are o soluție fezabilă optimă;
 3. este nemărginită.
- Dacă există o soluție fezabilă, atunci există și o soluție fezabilă de bază.
- Dacă există o soluție fezabilă optimă, atunci există și o soluție fezabilă de bază optimă.

Teorema 28. (Interpretare geometrică) Fie Ω , mulțimea convexă formată din toate soluțiile fezabile. Atunci \mathbf{x} este un punct extremal al lui Ω dacă și numai dacă \mathbf{x} este o soluție fezabilă de bază.

10.2. Algoritmul Simplex

1. Se transformă constrângerile problemei de programare liniară într-un sistem de ecuații liniare.
2. Se construiește tabloul simplex inițial. Se scrie funcția obiectiv pe ultimul rând.
3. Valoarea negativă (dacă există) din ultimul rând, de valoare absolută maximă, desemnează coloana pivot.
4. Se împarte fiecare linie la elementul acesteia (doar dacă acesta din urmă este pozitiv), situat în coloana pivot. Apoi, se determină cel mai mic termen liber din ultima coloană. Elementul situat la intersecția dintre linia acestuia din urmă și coloana pivot reprezintă elementul pivot.
5. Toate elementele de pe coloana pivot, cu excepția elementului pivot, se fac egale cu zero prin metoda lui Gauss.
6. Dacă există valori negative pe ultimul rând, se repetă pașii 3–5. Raționamentul se oprește atunci când nu mai există valori negative pe ultimul rând.

Problema 10

$$\begin{array}{ll} \text{maximizați} & 13x_1 + 23x_2 \\ \text{supusă la} & 5x_1 + 15x_2 \leq 480 \\ & 4x_1 + 4x_2 \leq 160 \\ & 35x_1 + 20x_2 \leq 1190 \\ & x_1 \geq 0, x_2 \geq 0 \end{array}$$

BIBLIOGRAFIE

- [1] Stephen Boyd, Lieven Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.
- [2] Edwin K.P. Chong, Stanislaw H. Zak, *An Introduction to Optimization*, Wiley, 2013.
- [3] Ion Necoară, *Metode de optimizare numerică*, Editura Politehnica Press, 2013.
- [4] Yurii Nesterov, *Lectures on Convex Optimization*, Springer, 2018.
- [5] Jorge Nocedal, Stephen J. Wright, *Numerical Optimization*, Springer, 2006.